Fikir Önerisi: Fatura Dedektifi

Evdeki tek sayaçtan hangi cihazın ne kadar elektrik harcadığını bulmak

Mert Güngör, Grup 14, Samsung Innovation Campus, Yapay Zekâ Kursu

1. Proje Fikri

Elektrik faturasında tek bir toplam yazar. Hangi cihazın ne kadar harcadığını göstermez, bu yüzden bir hane nereden tasarruf edeceğini ya da hangi tarifenin ona uygun olduğunu bilemez. Enerji maliyeti Türkiye'de ciddi bir yük. 2025'te nüfusun %19,5'i evini yeterince ısıtmaya gücünün yetmediğini söyledi [1]. Isınmada çoğunlukla doğal gaz kullanılıyor, ama cihaz cihaz azaltılabilen fatura elektrik faturası. Her cihaza ayrı sayaç takmak ise pahalı ve zahmetli.

Yalnızca evin toplam güç sinyaline bakarak buzdolabının, çamaşır makinesinin, bulaşık makinesinin, su ısıtıcının ve mikrodalganın ne kadar harcadığını tahmin eden bir model geliştirmek istiyorum (non-intrusive load monitoring, NILM). Sonuç, bir günün sayaç verisini cihaz bazında kWh ve TL'ye çeviren bir web demosu olacak. Demo günü Türkiye'nin tek zamanlı ve üç zamanlı (gündüz, puant, gece) tarifeleriyle fiyatlayacak, hangisinin daha ucuz olduğunu söyleyecek ve geceye kaydırmaya değer cihazı gösterecek. Başarıyı, modelin eğitimde hiç görmediği evlerde, her cihaz için watt cinsinden ortalama mutlak hata (MAE) ve toplam enerji hatasıyla ölçeceğim.

2. Sürdürülebilir Kalkınma Amaçlarıyla İlişkisi

Proje SDG 7'ye, Erişilebilir ve Temiz Enerji amacına hizmet ediyor. En çok hedef 7.3 (enerji verimliliğini artırmak) ile ilgili, çünkü insanlar ancak görebildikleri tüketimi azaltabilir. Hanelerin faturasını düşürmesine yardım ettiği için hedef 7.1 (uygun fiyatlı enerji hizmetleri) ile de dolaylı bir bağı var. Ayrıca SDG 12.8'i (sürdürülebilir yaşam için bilgi ve farkındalık) ve SDG 13'ü destekliyor, çünkü daha az elektrik tüketimi daha az emisyon demek.

3. Literatür Örnekleri

Kelly ve Knottenbelt (2015) [2] bu probleme üç farklı derin sinir ağı uyguladı ve İngiltere'deki evlerde beş cihaz üzerinde denedi. Ağlar, klasik yöntemlerden (combinatorial optimisation ve factorial hidden Markov model) daha yüksek ortalama F1 skoru aldı ve eğitimde görülmeyen bir evde de çalıştı. Zhang ve ark. (2018) [3] sequence-to-point öğrenmeyi önerdi: bir evrişimli ağ toplam sinyalin bir penceresini okuyor ve pencerenin ortasındaki anda tek bir cihazın gücünü tahmin ediyor. İki hata ölçütünde %84 ve %92 iyileşme bildiriyorlar.

İki çalışma da modelleri araştırma veri setlerinde değerlendiriyor. İkisi de sonucu haneler için bir araca ya da maliyet dökümüne çevirmiyor. Benim projem modeli birden fazla görülmemiş evde 1 dakikalık çözünürlükte test edecek ve sonucu Türkiye tarifeleriyle kWh ve TL olarak gösterecek.

4. Veri

Strathclyde Üniversitesi'nin REFIT Electrical Load Measurements (Cleaned) veri setini kullanacağım. CC BY 4.0 lisansıyla ücretsiz [4]. 2013 ile 2015 arasında İngiltere'de 20 evi kapsıyor. Her evde toplam güç ve 9 cihaz kanalı watt cinsinden, yaklaşık 8 saniyede bir kaydedilmiş, her ev için bir CSV dosyası var (arşiv 514 MB, açıldığında 6,9 GB ve 119,5 milyon satır). Veriyi indirip kontrol ettim. Buzdolabı ya da dondurucu 20 evde, çamaşır makinesi 19, mikrodalga 16, bulaşık makinesi 15 ve su ısıtıcı 15 evde ölçülmüş. Ev 2'de ölçülen dokuz cihaz enerjinin %32'sini açıklıyor ve dakikaların yaklaşık %25'inde veri yok. Veriyi 1 dakikaya yeniden örnekleyeceğim, boşluk içeren pencereleri çıkaracağım, her evin sütunlarını ortak cihaz adlarına eşleyeceğim, değerleri ölçekleyeceğim ve veri sızıntısını önlemek için ayırmayı ev bazında yapacağım.

Evler İngiltere'de ve Türkiye'den cihaz düzeyinde açık bir veri bulamadım, bu yüzden uyarlamayı dört adımda yapacağım. İki ülkede de şebeke 230 V ve 50 Hz, hedeflediğim beş cihaz Türk evlerinde de kullanılıyor. Birincisi, modeli ikinci bir veri setinde test edeceğim. D'Incecco ve ark. [5], REFIT ile eğitilen bir modelin başka bir İngiltere veri setinde 11,8 W, ABD evlerinde ise 32,1 W MAE verdiğini bildiriyor. ABD verisiyle eğitilen model orada 23,7 W'a iniyor. İkincisi, Türk evlerinde yaygın olup REFIT'te bulunmayan yükleri (klima, termosifon, çay makinesi) eğitim verisine yapay olarak ekleyeceğim. Üçüncüsü, modeli 1 dakikalık, 15 dakikalık ve saatlik çözünürlükte ölçeceğim, çünkü Türkiye'de kurulmakta olan akıllı sayaçların saatlik veri verdiği bildiriliyor. Dördüncüsü, bir Türk evinde akıllı prizlerle birkaç hafta ölçüm alıp hatayı o veri üzerinde raporlayacağım.

5. Yaklaşım: Derin Öğrenme

Bir makine öğrenmesi referansıyla birlikte derin öğrenmeyi seçiyorum. Girdi ham bir zaman serisi, cihazlar üst üste çalışıyor ve benzer güç çekiyor: Ev 2'de çamaşır makinesinin ve bulaşık makinesinin ısıtıcıları yaklaşık 2,1 ve 2,2 kW çekiyor. Modelin her cihazın çalışma döngüsünün şeklini öğrenmesi gerekiyor, bu da tek boyutlu evrişimli ağa (sequence-to-point) uygun. Her cihaz için küçük bir ağı ücretsiz Colab'de eğiteceğim. İki referans yöntemi şimdiden hesapladım: Ev 2'de eğitip Ev 5'te test ettim. Ortalama gücü tahmin etmek su ısıtıcıda 44,9 W, bulaşık makinesinde 107,1 W MAE veriyor, pencere istatistikleri üzerinde gradient boosting bunları 17,6 W ve 67,6 W'a indiriyor. Çamaşır makinesinde ise işe yaramıyor (44,3'ten 43,6 W'a), çünkü pencere istatistikleri bir döngüdeki aşamaların sırasını kaybediyor, evrişimli ağ ise koruyor. Hedefim, aynı test evlerinde beş cihazın en az dördünde gradient boosting'i geçmek.

Maliyet için EPDK'nın 4 Nisan 2026'dan itibaren geçerli mesken tarifesini kullanıyorum [6], vergileri hesaplayarak ekledim. Üç zamanlı tarifede kWh gece (22:00-06:00) 3,26 TL, gündüz 4,92 TL, akşam puant saatlerinde (17:00-22:00) 7,00 TL. Tek zamanlı tarifede günde 8 kWh'e kadar 3,24 TL, üstü 4,86 TL. Ev 2'nin gerçek bir gününü (10,34 kWh) fiyatladım: tek zamanlıda 37,28 TL, üç zamanlıda 49,95 TL tutuyor. Bulaşık ve çamaşır makinesi geceye kaydırılırsa üç zamanlı fatura 45,74 TL'ye iniyor, yani bu ev için tek zamanlı tarife yine daha ucuz. Demo aynı karşılaştırmayı her ev için yapacak.

Kaynaklar

[1] Eurostat, Inability to keep home adequately warm (ilc_mdes01), Türkiye, 2025. https://ec.europa.eu/eurostat/databrowser/view/ilc_mdes01/default/table
[2] Kelly, J., & Knottenbelt, W. (2015). Neural NILM: Deep Neural Networks Applied to Energy Disaggregation. ACM BuildSys '15. https://doi.org/10.1145/2821650.2821672
[3] Zhang, C., Zhong, M., Wang, Z., Goddard, N., & Sutton, C. (2018). Sequence-to-point learning with neural networks for non-intrusive load monitoring. AAAI-18. https://doi.org/10.1609/aaai.v32i1.11873
[4] Murray, D., Stankovic, L., & Stankovic, V. (2017). An electrical load measurements dataset of United Kingdom households from a two-year longitudinal study. Scientific Data, 4, 160122. https://doi.org/10.1038/sdata.2016.122
[5] D'Incecco, M., Squartini, S., & Zhong, M. (2019). Transfer Learning for Non-Intrusive Load Monitoring. IEEE Transactions on Smart Grid, 11(2), 1419-1429. https://doi.org/10.1109/TSG.2019.2938068
[6] EPDK, tariff tables for electricity bills, residential low-voltage tariff valid from 4 April 2026. https://www.epdk.gov.tr/Detay/Icerik/3-1327/elektrik-faturalarina-esas-tarife-tablolari