Fikir Önerisi: Fatura Dedektifi

Evdeki tek sayaçtan hangi cihazın ne kadar elektrik harcadığını bulmak

Mert Güngör, Grup 14, Samsung Innovation Campus, Yapay Zekâ Kursu

1. Proje Fikri

Elektrik faturasında tek bir toplam yazar. Hangi cihazın ne kadar harcadığını göstermez, bu yüzden bir hane nereden tasarruf edeceğini bilemez. Enerji maliyeti Türkiye'de ciddi bir yük. 2025'te nüfusun %19,5'i evini yeterince ısıtmaya gücünün yetmediğini söyledi [1]. Isınmada çoğunlukla doğal gaz kullanılıyor, ama cihaz cihaz azaltılabilen fatura elektrik faturası. Her cihaza ayrı sayaç takmak ise pahalı ve zahmetli.

Yalnızca evin toplam güç sinyaline bakarak buzdolabının, çamaşır makinesinin, bulaşık makinesinin, su ısıtıcının ve mikrodalganın ne kadar harcadığını tahmin eden bir model geliştirmek istiyorum. Bu problem literatürde non-intrusive load monitoring (NILM) olarak geçiyor. Sonuç, bir günün sayaç verisini cihaz bazında kWh ve TL dökümüne çeviren bir web demosu olacak. Başarıyı, modelin eğitimde hiç görmediği evlerde, her cihaz için watt cinsinden ortalama mutlak hata (MAE) ve toplam enerji hatasıyla ölçeceğim.

2. Sürdürülebilir Kalkınma Amaçlarıyla İlişkisi

Proje SDG 7'ye, Erişilebilir ve Temiz Enerji amacına hizmet ediyor. En çok hedef 7.3 (enerji verimliliğini artırmak) ile ilgili, çünkü insanlar ancak görebildikleri tüketimi azaltabilir. Hanelerin faturasını düşürmesine yardım ettiği için hedef 7.1 (uygun fiyatlı enerji hizmetleri) ile de dolaylı bir bağı var. Ayrıca SDG 12.8'i (sürdürülebilir yaşam için bilgi ve farkındalık) ve SDG 13'ü destekliyor, çünkü daha az elektrik tüketimi daha az emisyon demek.

3. Literatür Örnekleri

Kelly ve Knottenbelt (2015) [2] bu probleme üç farklı derin sinir ağı uyguladı ve İngiltere'deki evlerde beş cihaz üzerinde denedi. Ağlar, klasik yöntemlerden (combinatorial optimisation ve factorial hidden Markov model) daha yüksek ortalama F1 skoru aldı ve eğitimde görülmeyen bir evde de çalıştı.

Zhang ve ark. (2018) [3] sequence-to-point öğrenmeyi önerdi. Bir evrişimli ağ toplam sinyalin bir penceresini okuyor ve pencerenin ortasındaki anda tek bir cihazın gücünü tahmin ediyor. İki hata ölçütünde %84 ve %92 iyileşme bildiriyorlar.

İki çalışma da modelleri araştırma veri setlerinde değerlendiriyor. İkisi de sonucu haneler için bir araca ya da maliyet dökümüne çevirmiyor. Benim projem modeli birden fazla görülmemiş REFIT evinde 1 dakikalık çözünürlükte test edecek ve sonucu kWh ve TL olarak gösterecek.

4. Veri

Strathclyde Üniversitesi'nin REFIT Electrical Load Measurements (Cleaned) veri setini kullanacağım. CC BY 4.0 lisansıyla ücretsiz [4]. 2013 ile 2015 arasında İngiltere'de 20 evi kapsıyor. Her evde toplam güç ve 9 cihaz kanalı watt cinsinden, yaklaşık 8 saniyede bir kaydedilmiş. Biçim CSV, her ev için bir dosya. Arşiv 514 MB, açıldığında yaklaşık 6,9 GB ve 119,5 milyon satır.

Veriyi indirip kontrol ettim. Buzdolabı ya da dondurucu 20 evde, çamaşır makinesi 19, mikrodalga 16, bulaşık makinesi 15 ve su ısıtıcı 15 evde ölçülmüş. İki evi ayrıntılı inceledim. Ev 2'de ölçülen dokuz cihaz toplam enerjinin %32'sini, bulaşık makinesi tek başına %13'ünü açıklıyor. Ev 2'de dakikaların yaklaşık %25'inde veri yok. Ön işleme olarak veriyi 1 dakikaya yeniden örnekleyeceğim, boşluk içeren pencereleri çıkaracağım, her evin sütunlarını ortak cihaz adlarına eşleyeceğim ve değerleri ölçekleyeceğim. Veri sızıntısını önlemek için ayırmayı ev bazında yapacağım (eğitim, doğrulama ve test evleri). Bir sınır şu: evler İngiltere'de ve test edebileceğim Türkiye verisi yok. Cihazlar ve alışkanlıklar farklı, bu yüzden demodaki TL değerleri bir örnek olacak.

5. Yaklaşım: Derin Öğrenme

Bir makine öğrenmesi referansıyla birlikte derin öğrenmeyi seçiyorum. Girdi ham bir zaman serisi, cihazlar üst üste çalışıyor ve benzer güç çekiyor. Ev 2'de çamaşır makinesinin ve bulaşık makinesinin ısıtıcıları yaklaşık 2,1 ve 2,2 kW çekiyor. Modelin her cihazın çalışma döngüsünün şeklini öğrenmesi gerekiyor, bu da tek boyutlu evrişimli ağa (sequence-to-point) uygun. Her cihaz için küçük bir ağı ücretsiz Colab'de eğiteceğim.

İki referans yöntemi şimdiden hesapladım: Ev 2'de eğitip Ev 5'te 1 dakikalık çözünürlükte test ettim. Her cihazın ortalama gücünü tahmin etmek su ısıtıcıda 44,9 W, bulaşık makinesinde 107,1 W MAE veriyor. Pencere istatistikleri üzerinde gradient boosting bunları 17,6 W ve 67,6 W'a indiriyor. Çamaşır makinesinde (44,3'ten 43,6 W'a) ve mikrodalgada (30,2'den 30,0 W'a) ise işe yaramıyor. Pencere istatistikleri bir döngüdeki aşamaların (ısıtma, yıkama, sıkma) sırasını kaybediyor, evrişimli ağ ise koruyor. Bu yüzden en çok orada fayda bekliyorum. Hedefim, aynı test evlerinde beş cihazın en az dördünde hem MAE'de hem günlük enerji hatasında gradient boosting'i geçmek.

Kaynaklar

[1] Eurostat, Inability to keep home adequately warm (ilc_mdes01), Türkiye, 2025. https://ec.europa.eu/eurostat/databrowser/view/ilc_mdes01/default/table

[2] Kelly, J., & Knottenbelt, W. (2015). Neural NILM: Deep Neural Networks Applied to Energy Disaggregation. ACM BuildSys '15. https://doi.org/10.1145/2821650.2821672

[3] Zhang, C., Zhong, M., Wang, Z., Goddard, N., & Sutton, C. (2018). Sequence-to-point learning with neural networks for non-intrusive load monitoring. AAAI-18. https://doi.org/10.1609/aaai.v32i1.11873

[4] Murray, D., Stankovic, L., & Stankovic, V. (2017). An electrical load measurements dataset of United Kingdom households from a two-year longitudinal study. Scientific Data, 4, 160122. https://doi.org/10.1038/sdata.2016.122